

(2025) Explaining E/MEG source imaging and beyond: An updated review

<p>期刊: IEEE Journal of Biomedical and Health Informatics (发表日期: 2025)</p> <p>作者: Zhao Feng; Ioannis Kakkos; George K. Matsopoulos; Cuntai Guan; Yu Sun</p>
<p>摘要: <i>E/MEG source imaging (ESI) provides noninvasive measurements of brain activity with high spatial and temporal resolution. In particular, the wearability and portability of EEG make it an attractive area of research beyond the biomedical communities, especially given the broad application prospects including brain-computer interface (BCI), neuromarketing and neuroergonomics. Although existing reviews offer valuable insights, they often present ESI models in a relatively isolated manner and may not encompass the most recent advancements in the field. In this work, we aim to: 1) provide a timely indepth review of the widely-explored and state-of-the art ESI models, including their underlying neurophysiological assumptions and mathematical derivations; 2) list the primary applications of ESI and highlight crucial steps regarding its implementations; 3) discuss current challenges in ESI and propose future research prospects; 4) demonstrate practical usage and implementation details of various representative ESI models accompanied by open-source datasets and code (available at link). As a rapidly expanding field, ESI is continuously developing and evolving to integrate new technologies. We believe the widespread applications of ESI is happening, and it will dramatically expand our understanding of brain dynamics.</i></p>
<p>摘要翻译: <i>E/MEG 源成像 (ESI) 提供了具有高空间和时间分辨率的非侵入性脑活动测量。特别是，脑电图 (EEG) 的可穿戴性和便携性使其成为生物医学社区以外的一个有吸引力的研究领域，尤其考虑到其在脑-机接口 (BCI)、神经营销和神经人机工程等广泛应用前景。尽管现有的综述提供了有价值的见解，但它们往往以相对孤立的方式呈现 ESI 模型，并可能未涵盖该领域最新的进展。在本研究中，我们旨在：1) 提供对广泛探讨和最先进的 ESI 模型的及时深入综述，包括其基础神经生理假设和数学推导；2) 列出 ESI 的主要应用并突出其实施的关键步骤；3) 讨论 ESI 当前面临的挑战并提出未来的研究前景；4) 演示各种代表性 ESI 模型的实际使用和实施细节，并附上开放源代码的数据集和代码（可在链接处获取）。作为一个快速发展的领域，ESI 正在不断发展并演变以整合新技术。我们相信 ESI 的广泛应用正在发生，它将极大地扩展我们对脑动态的理解。</i></p>
<p>期刊分区: IF 6.8 SCI Q1 中科院 工程技术2区</p>

原文PDF链接: [Feng 等 - 2025 - Explaining MEG Source Imaging and Beyond An Updated Review.pdf](#)

笔记创建日期: 2025/10/23 22:27:11

1 文章基本框架

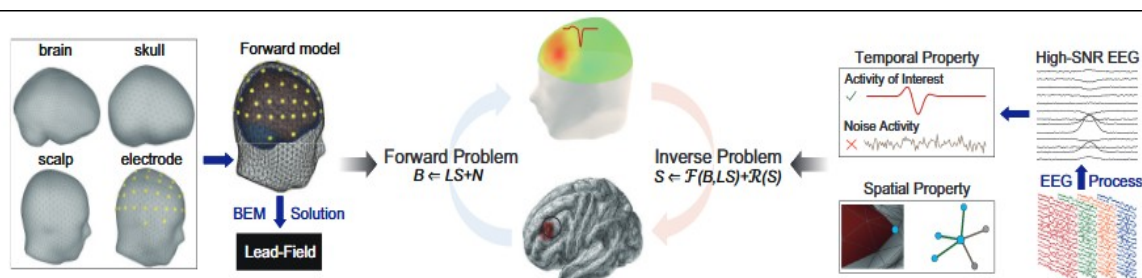
本文的简介和目的

本文详细说明了EEG和MEG源成像的基本原理，包括涉及的正演模型算法、反演算法，特别是各类成像算法的特性与优劣势都做了详细的说明，并说明了当下EEG源成像问题的一些难点。

源成像基本原理

$$B = LS + \varepsilon \quad (1)$$

- 其中 L 是导联矩阵，表示特定位置特定方向的单位偶极子在EEG电极上的记录。头部的几何形状和组织导电性的信息通过导联矩阵表示。**正确的前向计算估计导联矩阵对成像结果至关重要。**它与脑电头模型的数据来源（被试的MRI、CT还是公共模板）、头模型的选择（边界元模型BEM，有限元模型FEM）有很大影响。
- 其中 ε 表示观测噪声。



严重欠定，存在无穷的源组合满足式(1)。为了获得唯一的解，需要利用先验假设或者限制约束解空间。

源成像中比较成熟的可作为约束的先验

1. 解剖学上的约束

源信号一般视为在皮层的二维平面坐标上。

源信号的方向，一般视为垂直与皮层。或者自由定向，并用三个分量描述沿三个垂直坐标轴的源强度。

2. 空间先验

要产生可检测的EEG信号，大量神经细胞必须同步激活。所以，激活的源信号空间上应该是相对扩展的。生成可记录EEG所需的最小源区域为 $6 \sim 10 \text{ cm}^2$ ，MEG为 $3 \sim 12 \text{ cm}^2$ 。

从数学上讲，这些先验被作为空间正则化项纳入，强制相邻偶极子之间的平滑性和一致性，从而确保扩展和均匀的源激活。

3. 时间动态先验

1.时间连续性。源信号在时间维度上的平滑变化，**即相邻时间点的源活动应具有一定的相关性和渐变性**，以避免不符合神经生理特性的瞬时突变。引入时间平滑正则化项实现，从而保证估计的时序过程具有连续性。

2.时间持续性。源空间激活模式在时间上的稳定维持，脑功能状态在短时间内的相对恒定性。（及微状态现象）

4. 源信号稀疏先验

1.由于不同脑区承担不同功能，所以**大脑只有某几个特定的区域被激活，其余大部分区域保持相对静息。**

2.**全局稀疏性假设。**皮层活动在空间上是集中的，只有一小部分大脑对给定的刺激做出反应。

3.在数学上，这些先验强制限制潜在源块的数量，从而导致表现出‘块稀疏性’的源解决方案。

源成像算法

源的生成可靠性仍然不完全明确，而在ESI中加入约束极大依赖于用户的专业知识和主观判断。

- 偶极子拟合法

基于等效电流双极（ECD）模型，该模型假设少量偶极子产生E/MEG测量。在这一假设下，偶极子的数量是先验已知的，源成像的目的是拟合一组其场最能匹配测量结果的偶极子。目前研究表明仅用单个或少数离散的偶极子表示大范围的皮质活动过于简单。而对于弥散源，ECD模型有着先天的缺陷。

- 波束形成法

波束形成是一种空间滤波技术，主要目标是为每个源位置构建一个空间滤波器，使得只有从该源产生的神经活动能够通过空间滤波器，同时抑制来自大脑其他部分的活动。

- **分布式源方法**

目前最主流，最常见的源成像研究方法。基于分布式电流密度模型（distributed current density, DCD），该模型假设源活动是由分布在源空间中的电流偶极子产生的，**每一个偶极子对应一个源信号通道**。偶极子的位置预先指定在二维皮层表面或三维大脑体积上，并且每个可能的偶极子的信号强度是从E/MEG中估计得出的。这样，**源信号位置和方向都已经确定，只需去估计每个源信号的强度**。

1. 基于空间平滑的最小范数（MN方法）

$$S = \arg \min_S \|B - LS\|_{\Sigma_e^{-1}}^2 + \lambda \|MS\|_{Fro}^2 \quad (2)$$

其中 $\|X\|_{\Sigma_e^{-1}} = \sqrt{\text{trace}[X^\top \Sigma_e^{-1} X]}$ 为权重范数， Σ_e 为噪声协方差矩阵。 M 则表示对源信号的各种先验假设。

$M = I$ 时，为最小范数法（MNE）。由于MNE偏向表层源，后续又在此基础上引入了各种加权策略，为深层源分配更大的权重的算法wMNE和精确低分辨率脑电磁成像（eLORETA）。

而另一种策略是对 MNE 得到的解进行归一化，以消除深度偏见。如参数映射（dSPM）和标准化低分辨率脑电磁成像（sLORETA）。

最小范数方法的缺点是：通常会高估潜在源的空间范围，同时低估深层源；优点是：有解析解，计算高效，对正演问题的计算的导联矩阵 L 具有较好的鲁棒性。

2. 基于空间稀疏

空间稀疏的方法大多局灶，关注源位置信息，多数专注于瞬时情况：

$$s = \arg \min_s \|b - Ls\|_{\ell_p} + \lambda \|Ms\|_{\ell_q} \quad (3)$$

其中 $\ell_p (0 < p \leq 2)$, $\ell_q (0 < p \leq 1)$

瞬时稀疏约束方法的主要缺点：**通常导致时间上不连续的结果，并且未能重构基础源的时间活动。当稀疏源分散在真实情况周围时，结果可能难以解释。**

3. 贝叶斯方法

在贝叶斯框架下，源成像问题可以表达为从观测数据 $p(B)$ 和源信号先验 $p(S)$ 推断后验分布 $p(S|B)$

$$p(S|B) = \frac{p(B|S)p(S)}{P(B)} \quad (4)$$

所以，贝叶斯框架下，**MN方法**实际可以表示为以下的似然函数和先验分布：

$$p(B|S) \propto \exp\left(-\frac{1}{2}\|B - LS\|_{\Sigma_\epsilon^{-1}}\right) \quad (5)$$

$$p(S|\gamma) \propto \exp\left(-\frac{1}{2}\|S\|_{\Sigma_S^{-1}}\right), \quad \Sigma_S = \sum_{i=1}^{d_\gamma} \gamma_i C_i \quad (6)$$

Σ_S 源协方差的先验假设， $\gamma = [\gamma_1, \dots, \gamma_{d_\gamma}]$ 是一个包含 d_γ 个非负超参数的向量，用于控制每个**固定协方差基矩阵** C_i 的相对贡献。

贝叶斯方法的优势是：**允许对先验信息进行详细和灵活的描述，特别是关于神经活动的空间特性。**缺点（难点）：**如何合理地将神经科学知识转化为针对贝叶斯方法的数学可解约束。**

4. 时空混合求解法

同时利用源活动的**空间特性**和**时间约束**进行源成像。代表的方法有**态空间模型**：

$$s_t = F(s_{t-1}, s_{t-2}, \dots, s_{t-p}) + e_t \quad (7)$$

即当前时刻 t 的源信号，收到对应电流偶极子及其邻居偶极子前 p 个时刻状态共同决定。

其中 F 捕捉了源之间的相互作用，而 e_t 是状态噪声。通常使用**一阶自回归模型**来考虑时间平滑性，源信号的解可以通过卡尔曼滤波器或递归惩罚最小二乘程序获得。

为了减轻瞬时稀疏约束方法的时间不连续性，还有一类方法通过**混合范数同时约束空间和时间特征**：

$$S_{r,q} = \left(\sum_i \left(\sum_t w_{i,t} |S_{i,t}|^r \right)^{\frac{q}{r}} \right)^{\frac{1}{q}} \quad (8)$$

$w_{i,t}$ 为深度偏差的加权补偿，其中 $l_{2,1}$ （即 $\sum_i \sqrt{\sum_t w_{i,t} S_{i,t}^2}$ ）是非常常用的方法，**强制解的空间稀疏性和时间连续性。估计源 S 在空间上是稀疏的（即，行稀疏的），并且每个体素的时间系数要么是同时非零的，要么以行结构稀疏的方式全部设置为零。**

另一种策略使用**时间基函数（TBFs）**来对时间信息进行建模，源活动可以建模为TBFs的线性组合：

$$S = W\Phi = \sum_k W_k \Phi_k \quad (9)$$

$\Phi = [\Phi_1 \dots \Phi_k]^\top \in \mathbb{R}^{k \times T}$ 表示 k 个预先设定的时间基函数， $W = [W_1 \dots W_k] \in \mathbb{R}^{D \times k}$ 是指定时间基函数对每个源偶极子的贡献的权重系数。

这类方法的**优势是：可以有效地重构源活动的时空动态，促进ESI解的时间连续性。通过将信号投影到由TBF跨度构成的子空间中来促进源重建，在该子空间中，感兴趣活动的信噪比可以得到改善。难点是：大规模时间尺度上的脑活动的非平稳性可能违反时间连续性假设。为了优化源重建的准确性和可靠性，建议确定脑活动连续的最佳时间段。**

5.深度学习方法

自动从大量训练数据中学习约束，从而产生一个作为 L^{-1} 的逆函数 f_ϕ ：

$$\min \|S - f_{\phi}(B)\|^2$$

优势：计算快速，不需要手动确定正则化来编码源信号的先验特性，直接通过数据驱动学习观测的EEG和源信号之间的映射。

缺点：源成像天然缺少ground-truth，所以十分依赖数值仿真的数据，然而仿真数据无法完美拟合真实神经信号源激活情况，且头模型的选择以及计算数据来源对导联矩阵的影响很大，从而体现在仿真数据与真实数据之间的差异上。而深度学习方法很容易过拟合于仿真数据，导致导联矩阵拟合不准确的误差被进一步放大，泛化性十分受限。

可以使用**迁移学习**技术，即在大型合成数据集上预训练的模型可以在真实世界数据集上进行微调来解决泛化性问题。也可以采用**算法展开方法**，结合传统正则化框架和深度学习之间的共同优势，实现可解释性的神经网络建模ESI问题。

源成像需要考虑的事项

1. 导联矩阵计算是否合理

对正演问题（即导联矩阵 L ）的精确求解对于可靠的ESI结果至关重要，否则会在源估计中导致**系统性误差**。正问题的解依赖于许多因素，如**大脑解剖**（组织的几何形状和导电性）和**电极布局**。大脑解剖又受到脑电头模型的数据来源（被试的MRI、CT还是公共模板，New York Head, ICBM 152）、头模型的选择（边界元模型BEM，有限元模型FEM）的影响。

前向建模不准确本质上是导联矩阵 L 计算不准确。对于**导联矩阵建模存在较大偏差的场景**，**二范数正则化 + 全局约束**的方法如：MNE, sLORETA, dSPM都倾向于生成**平滑、低能量的源分布，不会过度拟合 L 中的不确定性**。

2. 通道数目是否满足最低的基线需求

一般来说，准确进行源信号重构至少要求**64导联**，低于64导联成像质量难以保证。

3. 背景噪声协方差计算

鉴于ESI问题的准静态假设，即源电位的总和为零，头皮测量可以使用常平均参考进行中心化。**通常使用刺激前的基线活动、静息态数据进行估计，或者在基线不可用时直接使用单位矩阵计算噪声协方差矩阵。**

当下源成像问题存在的挑战

1. 没有真实源标签进行参考

由于没有真实源标签，一种策略是从ESI 结果中去验证和特定任务相关的一些以被广泛证实的共性生理特征、涉及的特定脑区、预期激活的生物标志等。在条件允许的情况下，更可靠的验证方法是使用多模态生理信号进行交叉验证，尤其是那些与头皮 EEG 共享相同发电源的颅内记录。

2. 难以准确重构深层源

具体而言，由于深层源距离头皮传感器较远，其产生的信号本质上很微弱。此外，深层源的活动往往被误认为来源于表层位置。

3. 缺乏清晰的背景活动拟合噪声协方差

部分场景（特别是静息态数据）缺乏清晰的背景活动来拟合背景噪声，噪声协方差矩阵难以获取，以及重构后的阈值选择困难。

4. 成像算法实时性有限

目前，被广泛应用的源成像算法多数是基于 L_2 范数约束，而一些约束更加精确的算法往往需要较高的计算量，而且存在部分超参数需要手动确定和选择。深度学习方法虽然实时性好，但泛化性普遍较差。最近大规模预训练模型的快速发展似乎为在各种条件下实现快速 ESI 提供了有前景的解决方案。

2 文章总结和思考

1. 总结

本文从源成像的基本原理，成像中的先验约束，各类的成像算法，成像中的注意事项，当下成像中的挑战对源成像问题进行了扫盲和解释。基本满足对成像问题的入门了解。

2. 思考

①文章对源信号没有真实标签的问题提出了一个很有创造性的建议：使用迁移学习技术，在仿真数据上进行预训练，在真实EEG数据集上进行微调来解决泛化性问题。

②对于当下的抑郁症识别或者生物标志物的研究中，存在两个比较棘手的问题：1. 缺少清晰的背景活动来拟合协方差矩阵。2. 普遍缺少被试自身的影像学数据来计算

导联矩阵。同时由于被试的差异，不同被试的导联矩阵的差异是很大的。所以稳妥的方法还是采用一些对导联矩阵有一定鲁棒性的**最小范数**方法，例如 **wMNE, eLORETA, dSPM和sLORETA等**。

③文章没有介绍算法展开的一些成像方法，也许**算法展开 + 迁移学习**会是一个比较具有前景的成像算法研究方向。