

(2023) Global adaptive transformer for cross-subject enhanced EEG classification

期刊: IEEE Transactions on Neural Systems and Rehabilitation Engineering (发表日期: 2023)

作者: Yonghao Song; Qingqing Zheng; Qiong Wang; Xiaorong Gao; Pheng-Ann Heng

摘要: Due to the individual difference, EEG signals from other subjects (source) can hardly be used to decode the mental intentions of the target subject. Although transfer learning methods have shown promising results, they still suffer from poor feature representation or neglect long-range dependencies. In light of these limitations, we propose Global Adaptive Transformer (GAT), an domain adaptation method to utilize source data for cross-subject enhancement. Our method uses parallel convolution to capture temporal and spatial features first. Then, we employ a novel attention-based adaptor that implicitly transfers source features to the target domain, emphasizing the global correlation of EEG features. We also use a discriminator to explicitly drive the reduction of marginal distribution discrepancy by learning against the feature extractor and the adaptor. Besides, an adaptive center loss is designed to align the conditional distribution. With the aligned source and target features, a classifier can be optimized to decode EEG signals. Experiments on two widely used EEG datasets demonstrate that our method outperforms state-of-the-art methods, primarily due to the effectiveness of the adaptor. These results indicate that GAT has good potential to enhance the practicality of BCI.

摘要翻译: 由于个体差异，来自其他受试者（源）的 EEG 信号很难用于解码目标受试者的心理意图。尽管迁移学习方法已显示出良好的效果，但它们仍然存在特征表示不足或忽视长距离依赖的问题。鉴于这些局限性，我们提出了全球自适应变压器（GAT），这是一种利用源数据进行跨受试者增强的领域适应方法。我们的方法首先使用并行卷积提取时间和空间特征。然后，我们采用一种基于注意力的新型适配器，隐式地将源特征转移到目标领域，强调 EEG 特征的全局相关性。我们还使用一个判别器，通过对特征提取器和适配器进行对抗学习，明确驱动边际分布差异的减少。此外，还设计了一种自适应中心损失来对齐条件分布。通过对齐的源和目标特征，可以优化分类器以解码 EEG 信号。在两个广泛使用的 EEG 数据集上的实验表明，我们的方法优于最先进的方法，主要是由于适配器的有效性。这些结果表明，

GAT 在增强脑机接口 (BCI) 实用性方面具有良好的潜力。


期刊分区: IF 5.2 SCI Q1 中科院 工程技术2区

原文PDF链接: [Song 等 - 2023 - Global adaptive transformer for cross-subject enhanced EEG classification.pdf](#)


笔记创建日期: 2025/11/11 09:47:37

1 文章基本框架

本文将transformer中的Q, K, V与预适应的目标域和源域相结合, 实现跨被试的EEG运动想象解码。主要创新点: **Q, K为目标域EEG经过特征提取层后的数据, K为特征提取层后的源域数据。**



1.特征提取层



利用并行的时间卷积+空间卷积提取时空特征并且最终通过元素相加进行融合。

1. EEG: $C \times T$ (C 为电极通道数, T 为时间样本数) ----> 时间卷积, 卷积核($k \times 1 \times n$)。 k : 特征图数量 (number of feature maps) n : 沿时间维度的卷积核长度 (kernel length along the temporal dimension) -----> **输出维度**: $k \times C \times (T - n + 1)$

-----> 空间卷积, 卷积核($k \times m \times 1$)
。 m : 通常等于电极通道数 C 。 -----> **输出维度**: $k \times 1 \times T$


2. 时间卷积输出 $k \times C \times (T - n + 1)$ -----> 时间分支重塑卷积, 卷积核($1 \times m \times 1$) -----> **输出维度**: $k \times 1 \times (T - n + 1)$

空间卷积输出 $k \times 1 \times T$ -----> 空间分支重塑卷积, 卷积核($1 \times 1 \times n$)

----->输出维度: $k \times 1 \times (T - n + 1)$

3.最终相加，拼接得到特征提取层输出维度: $k \times 1 \times (T - n + 1)$

2.迁移学习层(全局域适应层，对应公式1中的A)



Q, K为目标域EEG经过特征提取层后的数据，K为特征提取层后的源域数据。这里可以理解为：用目标域的数据特征的相关性去修正源域数据特征，并将修正后的数据作为域鉴别中的源域数据。（传统域鉴别是直接 $F(x^s)$ 和 $F(x^t)$ 进行对比，本文是 $A(F(x^s))$ 和 $F(x^t)$ 进行域鉴别）

• 引入“全局上下文”的对齐维度

DANN 等方法直接对齐特征点，通常只能捕捉到局部的、统计学上的分布接近（如均值、方差）。 A 是基于 Transformer 的注意力机制设计的，它能够捕捉 EEG 信号中的长程依赖关系。通过 $A(F(x^s))$ ，源域特征不再是孤立的数据点，而是被赋予了符合目标域逻辑的“全局背景”。判别器 D 现在不仅是在判断“数值分布像不像”，而是在判断“全局上下文逻辑像不像”。

• 实现从“被动对齐”到“主动适配”的转变

传统DANN特征提取器 F 被迫学习一套对两个域都“模棱两可”的通用特征，这往往会牺牲掉受试者特有的、具有判别性的信息。引入 A 后， F 可以专注于提取稳健的基础特征，而由 Global Adaptor 承担“翻译官”的角色。 A 利用目标域的 Query (Q) 和 Key (K) 来指导源域 Value (V) 的变换。这意味着源域特征在进入判别器之

前，已经经过了一层针对目标域特征分布的“主动润色”，使得后续的对抗对齐更加平滑和精准。

• 提升了对抗博弈的灵活性

在优化过程中，判别器 D 会寻找能够区分 $A(F(x^s))$ 和 $F(x^t)$ 的最大差异。增加了一个优化维度。如果判别器发现源域特征的全局关联不自然，注意力机制 A 会自动调整权重来修补这些逻辑漏洞。消融实验证明，移除 A 后，平均准确率大幅下降（在 Dataset 2a 上下降 9.45%），这说明 A 提供的“全局逻辑对齐”对判别器来说至关重要。

3. 迁移学习损失函数设置与参数学习策略

3.1 域鉴别损失

用DANN中的对抗思想去构建损失函数，通过一个可学习的判别器（Discriminator）自动寻找能区分两个分布的最优度量函数。而原始的DANN本质上是一个**二分类任务**，**等价于**衡量的是两个分布之间的 **JS 散度**，当两个分布完全不重叠时，JS 散度的梯度会消失，导致训练不稳定。

本文用Wasserstein 距离衡量两个分布的差异，即便两个分布相距很远，该距离也能提供连续且有意义的梯度，显著改善了训练的稳定性。

$$\begin{aligned}\mathcal{L}_D &= \mathbb{E}_{x^s \sim \mathcal{D}^s} [D(A(F(x^s)))] \\ &\quad - \mathbb{E}_{x^t \sim \mathcal{D}^t} [D(F(x^t))] + \lambda_{gp} GP(\hat{x}), \\ GP(\hat{x}) &= \mathbb{E}_{\hat{x} \sim \mathcal{D}_{\hat{x}}} [(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1)^2],\end{aligned}\tag{1}$$

$\mathcal{L}_D$ ：域判别器的损失函数，采用了 **Wasserstein 距离**来衡量源域和目标域特征分布的差异。 F ：特征提取器（Feature Extractor）。 A ：全局自适应器（Global Adaptor），仅作用于源域数据 x^s 。 D ：域判别器（Discriminator），用于区分特征是来自动源域还是目标域。**最终输出的值是一个分数，通过分数的大小区分目标域和源域。** $GP(\hat{x})$ ：梯度惩罚项（Gradient Penalty），用于确保对抗学习过程的训练稳定性。

最小化 $\mathcal{L}_D$ 等价于调小 $\mathbb{E}[D(A(F(x^s)))]$ ，调大 $\mathbb{E}[D(F(x^t))]$ ，为了使整体损失 $\mathcal{L}_D$ 变小，**判别器 D 会倾向于给映射后的源域特征打更低的分数，给目标域特征打更高的分数。****结论：**经过判别器 D 的训练，它会建立这样一套标准：**“分数越高越像目标**

域，分数越低越像源域”。

作用：通过优化 $\mathcal{L}_D$ ，最大化源域和目标域的得分差。这实际上是在寻找两个分布之间最不相似的地方。让 D 知道什么样的特征属于源域还是目标域。

论文实际上是在 DANN 的对抗路线上进行了优化升级，通过 WGAN-GP 的引入解决了传统DANN的痛点：

1. DANN 优化的是 JS 散度。当源域和目标域完全不重叠时，判别器太容易区分它们，导致梯度为 0（梯度消失）。
2. GAT (本文) 优化的是 Wasserstein 距离。即便两个域分布完全不同，它也能提供线性、平滑的梯度，告诉网络“往哪个方向改能让目标域和源域更像”。

3.2生成器/适配任务损失 (Generator/Adaptation Loss)

$$\mathcal{L}_G = -\mathbb{E}_{x^s \sim \mathcal{D}^s} [D(A(F(x^s)))] \quad (2)$$

在域鉴别学习中，域鉴别器 D 论文指出判别器由**两层全连接层**组成，通过优化域鉴别损失 $\mathcal{L}_D$ 更新 D ， D 学会了一件事：**给目标域数据打高分，给源域数据打低分。** $\mathcal{L}_G$ 的作用就是**让源域数据得高分，就是让源域特征看起来像目标域特征。通过优化 $\mathcal{L}_G$ ，强迫特征提取器 F 和适配器 A 修改它们的参数，使得源域数据经过处理后，能获得判别器 D 的高分。即实现源域数据和目标域对齐，联合优化损失没有这一项，就没有迁移学习能力，因为特征分布根本没对齐。**

这里可以这样理解 D 、 $\mathcal{L}_D$ 和 F 、 A 、 $\mathcal{L}_G$ 的关系：①**判别器 D 识别源域和目标域的能力随着 $\mathcal{L}_D$ 更新逐渐增强。**② **F 、 A 包括特征提取和源于数据全局自适应网络，它们对齐源域和目标域特征的能力随着 $\mathcal{L}_G$ 更新逐渐增强。**③**所以判别器 D 的损失 $\mathcal{L}_D$ 和 F 、 A 的损失 $\mathcal{L}_G$ 交替更新，判别器 D 就像考官， F 、 A 就像学生。 $\mathcal{L}_D$ 优化就像考官去学习两类数据最新的差异，保持火眼金睛。 $\mathcal{L}_G$ 优化就像学生（特征提取器）为了过关，必须学会模仿目标域的精髓。**

最终，随着 D 识别源域和目标域的能力越强， F 、 A 为了混淆 D ，必须具备更好的将源域和目标域特征对齐的能力，因此 F 、 A 最终具备了对齐目标域和源域的能力。

3.3 分类损失

原文是弱监督或者半监督场景，有少量目标域校准数据，并且有数据的标签。对于**无监督域自适应场景**，交叉熵分类损失公式如下：

$$\mathcal{L}_{cls}^{UDA} = -\mathbb{E}_{(x^s, y^s) \sim \mathcal{D}^s} \left[\sum_{c=1}^M y_c^s \log(C(F(x^s))_c) \right] \quad (3)$$

3.4 自适应中心损失

$$\mathcal{L}_{act} = \mathbb{E}_{x \sim \mathcal{D}^s} \|A(F(x_c^s)) - \mathbf{c}_{y_c}^t\|^2 + \mathbb{E}_{x \sim \mathcal{D}^t} \|F(x_c^t) - \mathbf{c}_{y_c}^t\|^2 \quad (4)$$

这里 $\mathbf{c}_{y_c}^t$ 表示目标领域中 c 类标签的特征中心。自适应中心损失的目的：不仅要让源域和目标域“整体像”（边缘分布对齐），还要让它们在“每一个类别上都对应”（条件分布对齐）。这里先解释概率论的一些知识：

1. 联合分布 Joint Distribution $P(X, Y)$

两个随机变量 X 和 Y **同时发生**的概率分布。源域有自己的联合分布 $P(x^s, y^s)$ ，目标域有自己的联合分布 $P(x^t, y^t)$ 。由于个体差异，这两个分布是不一样的。

2. 边缘分布 Marginal Distribution $P(X)$

不考虑另一个变量 Y 的取值，仅考虑 X 独自发生的概率分布。论文中的 **判别器 (Discriminator)** 和 **对抗损失** $\mathcal{L}_D, \mathcal{L}_G$ 做的事情，就是要让源域的 EEG 信号看起来和目标域的一模一样，**哪怕我们还不知道这些信号代表什么标签类别。**

3. 条件分布 Conditional Distribution $P(Y|X)$

在已知 X 发生的前提下， Y 发生的概率。对齐条件分布：适应性中心损失 (Adaptive Center Loss, $\mathcal{L}_{act}$)，在运动想象中它确保所有代表“左手”的源域信号，在转换后，真的和目标域“左手”的信号聚在一起，而不是跑偏变成了“右手”。也就是让 $P(y^s|x^s)$ 和 $P(y^t|x^t)$ 对齐。

对抗学习本质上是使用判别器 D 和全局自适应器 A ，强行把源域的边缘分布 $P(x^s)$ 拉得和目标域 $P(x^t)$ 一样。而这里的中心损失，在第一步的基础上，进一步拉近同类样本，对齐条件分布：让 $P(y^s|x^s)$ 和 $P(y^t|x^t)$ 对齐。

3.5 联合优化损失函数

$$\mathcal{L}_{joint} = \mathcal{L}_{cls} + w_G \mathcal{L}_G + w_{act} \mathcal{L}_{act} \quad (7)$$

对于整个网络，设置了两个优化器并交替训练，一个使用 $\mathcal{L}_D$ 优化判别器 D ，另一个使用上面的联合损失 $\mathcal{L}_{joint}$ 优化特征提取器 F 、全局适配器 A 和分类器 C 。

训练方式：

Algorithm 1 Global Adaptive Transformer

- 1: **Input:** Source EEG data $x^s \in \mathbb{R}^{C \times T}$, source label y^s , target EEG data $x^t \in \mathbb{R}^{C \times T}$, target label y^t .
 - 2: **Output:** y^{pred} , prediction results of target data.
 - 3: **Initialize:** the networks of feature extractor F , adaptor A , discriminator D , and classifier C with normal weights.
 - 4: **while** not converaged **do**
 - 5: **Update D :**
 - 6: obtain $D(A(F(x^s)))$ and $D(F(x^t))$;
 - 7: compute the loss $\mathcal{L}_D$ by **Eq. 4**;
 - 8: update D weights with $\mathcal{L}_D$;
 - 9: **Jointly Update F , A , and C :**
 - 10: obtain $D(A(F(x^s)))$;
 - 11: compute the loss $\mathcal{L}_G$ by **Eq. 6**;
 - 12: obtain $C(A(F(x^s)))$ and $C(F(x^t))$;
 - 13: compute the loss $\mathcal{L}_{cls}$ by **Eq. 7**;
 - 14: obtain $A(F(x^s))$ and $F(x^t)$;
 - 15: compute the loss $\mathcal{L}_{act}$ by **Eq. 8**;
 - 16: update F , A , and C weights with $\mathcal{L}_{joint}$ by **Eq. 9**;
 - 17: **end while**
 - 18: **Return:** F and C trained with aligned x^s and limited x^t .
 - 19: **Testing or Online Phase:** decode newly arrived target EEG trials $x^{t'}$ with trained F and C .
-

2 结果与讨论

实验结果全方位支撑了论文的三个主要观点：

1. **全局关联很重要**：Global Adaptor 是提升性能的最大功臣。
2. **双重对齐很必要**：结合对抗学习（边缘分布）和中心损失（条件分布）能达到最佳效果。
3. **结构保留很关键**：并行卷积比传统的串行卷积更适合 EEG 特征提取。

3 文章亮点思考

1、本文有什么优缺点？你是否对某些内容产生了疑问？

这种利用transformer注意力在迁移学习中有先例吗，还有哪些注意力机制可以引入？

1.1优点

架构设计的合理性：提出了**并行卷积**，这种“双流”设计相比于串行网络，保留了最原始的时空特征。

抓住了 EEG 的核心痛点：CNN 擅长提取局部特征，捕捉全局依赖关系的能力较弱，故引入 Transformer 的自注意力机制。

对齐策略的完备性：不仅做了边缘分布对齐（WGAN-GP），还做了条件分布对齐（Adaptive Center Loss）。这是一个非常成熟且“无死角”的迁移学习框架。

1.2关于 Attention 的发散思维，还有哪些注意力机制可以引入？

通道注意力 (Channel Attention / SE-Block)：EEG 的不同通道（电极）重要性不同。比如运动想象主要激活 C3、C4 电极。可以引入 SE-Block，自动给包含关键信息的通道加权，抑制噪声通道。

时间注意力 (Temporal Attention)：在 4 秒的运动想象任务中，并不是每一毫秒都包含判别信息（可能只有中间 2 秒是 ERD 现象最明显的）。可以引入时间注意力机制，让网络只“盯着”关键时间段看。

空间-拓扑注意力 (Graph Attention, GAT)：Transformer 的注意力是全连接的（所有点看所有点）。但大脑是有拓扑结构的（相邻电极关系更密切）。利用 **图神经网络**

(GCN) 结合注意力，根据电极在头皮上的物理位置构建邻接矩阵，可能比纯 Transformer 更符合脑科学先验

2、你是否认为某些研究方式可以改进，如何改进？

本文仅仅针对部分目标域有标签和数据的情况，如果是无监督域适应场景，如何改进这里的自适应边缘损失的方法，例如伪标签？如果更扩展一些，源域连数据都不可见的域泛化场景又该如何解决？

2.1 场景 A：无监督域适应 (UDA) —— 目标域完全无标签

本文只使用于目标域数据有部分标签可以用的情况，争对这个问题可以发散到**无监督域适应领域**，即引入**伪标签策略**：

1. 在**无监督域适应**场景下，最通用的做法是使用**伪标签**来代替真实标签。我们利用分类器当前的预测结果 $\hat{y}^t = C(F(x^t))$ 来猜测样本的类别，并据此更新公式。

修正后的公式 (基于伪标签)

需要引入一个**置信度阈值** (Confidence Threshold, τ)，只对那些模型非常确定的目标域样本计算中心损失，防止错误的预测带偏了中心。

$$\mathcal{L}_{act}^{UDA} = \mathbb{E}_{(x^s, y^s) \sim \mathcal{D}^s} \|A(F(x^s)) - \hat{\mathbf{c}}_{y^s}^t\|^2 + \mathbb{E}_{x^t \sim \mathcal{D}^t, \max(P) > \tau} \|F(x^t) - \hat{\mathbf{c}}_{\hat{y}^t}^t\|^2 \quad (5)$$

变量变化的详细解释

① $\mathbf{c}_{y_c}^t$ 变成了 $\hat{\mathbf{c}}_{\cdot}^t$ (伪中心)：

以前：直接用带标签的目标域数据计算中心。**现在**：在每个 Batch 或 Epoch 结束时，收集所有**预测置信度高**的目标域样本，计算它们的特征均值，作为“伪中心”。

② x_c^t 变成了 x^t with $\hat{y}^t$ (伪标签)：

以前：根据真实标签分类。**现在**：根据分类器 C 输出的最大概率对应的类别 ($\hat{y}^t = \arg \max C(F(x^t))$) 来决定它属于哪一类。

③ 增加 $\max(P) > \tau$ (阈值筛选)：

这是无监督场景特有的。如果分类器对某个目标域样本的预测模棱两可（比如概率

是 0.3, 0.3, 0.4)，那么这个样本是“危险”的，计算中心损失时必须**剔除**它，否则会把中心拉偏。通常 τ 设为 0.9 或更高。

2. 替代方案：向源域中心对齐 (Source Center Alignment)

如果觉得计算动态的“伪目标中心”太不稳定（因为刚开始训练时预测都很不准），还有一种更稳健的变体：**强迫目标域数据直接向源域的中心靠拢**。因为源域有标签，源域中心 $\mathbf{c}^s$ 是绝对准确的：

$$\mathcal{L}_{act}^{Simple} = \mathbb{E}_{x^t \sim \mathcal{D}^t, \max(P) > \tau} \|F(x^t) - \mathbf{c}_{\hat{y}^t}^s\|^2 \quad (6)$$

这种方案的区别：

- **原方案**：源域跑去凑目标域的热闹 (Source $\rightarrow$ Target Center) 。
 - **此方案**：目标域跑来凑源域的热闹 (Target $\rightarrow$ Source Center) 。在完全无监督且目标域数据分布未知的情况下，这通常是一个更安全的冷启动策略。（这里可以关注先进的伪标签策略）
3. 在**完全无监督域自适应 (UDA)** 场景下，由于没有目标域标签，使用固定的“中心损失”容易被错误的伪标签带偏。为了替换掉原来的 $\mathcal{L}_{act}$ ，目前学术界有几种非常成熟且先进的**伪标签策略 (Pseudo-labeling Strategies)**。

这些策略的核心目标是：**提高伪标签的质量**，防止“一步错，步步错” (Error Accumulation) 。以下是几种可以替换 Adaptive Center Loss 的主流策略：

1. 基于原型的伪标签 (SHOT - Source HypOthesis Transfer)

这是目前 UDA 中最接近“中心损失”思想，但更鲁棒的方法。它不直接使用单一的样本预测作为伪标签，而是利用**加权原型 (Weighted Prototypes)**。

• 策略逻辑：

- i. 先用源域数据计算出一组初始的分类中心（原型）。
- ii. 对于目标域数据，不看它在分类层输出的概率，而是看它在特征空间里**离哪个中心最近**（基于余弦相似度）。
- iii. **软伪标签**：根据距离生成软标签，而不是硬的一刀切。

• 数学表达：

假设 $\mathbf{w}_c$ 是第 c 类的原型向量， f_t 是目标特征：

$$\hat{y}_t^{(c)} = \frac{\exp(\cos(f_t, \mathbf{w}_c)/\tau)}{\sum_j \exp(\cos(f_t, \mathbf{w}_j)/\tau)}$$

- **替换优势**：相比于 $\mathcal{L}_{act}$ 依赖欧式距离和硬标签，SHOT 利用特征的**角度对齐**，在处理 EEG 这种高维、模长变化大的数据时更稳健。

2. 一致性正则化 (Consistency Regularization / FixMatch)

这是目前在半监督和无监督学习中最“能打”的策略之一。它的核心思想是：**对同一个 EEG 样本做不同的干扰（数据增强），模型的预测结果应该保持一致。**

• 策略逻辑：

- 弱增强**：对目标域样本 x^t 做轻微扰动（如极小的高斯噪声），得到预测结果作为**伪标签**。
- 强增强**：对同一个 x^t 做剧烈扰动（如随机掩码 masking、信号翻转、更强的噪声），得到预测结果。
- 对齐**：强制“强增强”的预测去逼近“弱增强”的伪标签。

• 损失函数：

$$\mathcal{L}_{cons} = 1(\max(p_{weak}) > \tau) \cdot \|p_{strong} - \text{Pseudo}(p_{weak})\|^2$$

- **替换优势**：它不依赖“中心”的几何假设，而是利用了 EEG 信号的**局部平滑性**。这能有效过滤掉那些位于决策边界附近的低质量伪标签。

3. 类别平衡自训练 (CBST / CRST)

EEG 数据经常存在类别不平衡问题（例如，人在静息态的时间远多于想象运动的时间）。普通的伪标签策略会倾向于把所有样本都预测为“大类”。

• 策略逻辑：

- 不使用统一的置信度阈值（比如 0.9）。
- 动态阈值**：为每一个类别 c 单独计算一个阈值 τ_c 。
- 按比例选取**：确保每一类选出的伪标签样本数量是平衡的，强制模型去学习那些“难学”的少样本类别。

- 数学思想：

$$\min_{\hat{Y}} \sum -\log P(\hat{y}|x) \quad \text{s.t.} \quad \text{ClassBalanceConstraints}$$

- **替换优势**：防止模型坍塌到某一个单一类别（Trivial Solution），这在无监督中心损失中是一个常见风险。

4. 邻域聚类 (Neighborhood Clustering / AaD)

这是一种完全基于特征几何结构的策略，不依赖分类器的输出概率。

- 策略逻辑：

- i. 对于每一个目标域样本，在特征空间中找到它的 K 个**最近邻居** (Nearest Neighbors)。
 - ii. **投票机制**：假设“近朱者赤”，如果周围的邻居都倾向于某一类，那么这个样本也应该是该类。
 - iii. **对比损失**：拉近样本与其邻居的距离，推远与其他样本的距离。
- **替换优势**： $\mathcal{L}_{act}$ 是找“全局中心”，而邻域聚类是找“局部圈子”。对于 EEG 这种个体差异极大的数据，局部结构往往比全局中心更可靠。

如果想替换掉 $\mathcal{L}_{act}$ ，建议的优先级如下：

1. 首选：SHOT (基于原型的伪标签)

- **理由**：它和原文的“中心损失”在几何直觉上一脉相承，改动最小，但效果通常更好，因为它不需要硬标签。
- **实现难度**：低。

2. 进阶：FixMatch (一致性正则化)

- **理由**：如果你能为 EEG 设计出好的数据增强方法（比如随机切片、频段遮盖），这个方法通常能达到 SOTA（当前最佳）效果。
- **实现难度**：中（需要设计增强模块）。

3. 兜底：熵最小化 (Entropy Minimization)

- 如果不想太复杂，直接加一个 $H(P(y|x^t))$ 损失，强迫预测变得自信。这通常作为辅助项配合上述任何一种策略使用。

2.2 域泛化 (Domain Generalization, DG) —— 源域数据不可见/不可接触

1. 元学习 (Meta-Learning / Episodic Training):

在训练源域模型时，不要把所有源域数据混在一起训练。而是模拟“跨域”过程：把源域分成 N 份，每次用 $N-1$ 份训练，在剩下的 1 份上测试。让模型在训练阶段就学会“如何快速适应新环境”。

2. 特征解耦 (Feature Disentanglement):

设计两个编码器，一个提取 **领域专属特征** (Domain-specific) (如个体的噪声、伪迹)，一个提取 **领域无关特征** (Domain-invariant) (如运动意图)。强制让分类器只使用领域无关特征。

3. 源无关域自适应 (Source-Free Domain Adaptation, SFDA):

这是最近的大热点。假设你拿不到源域数据，只能拿到一个**预训练好的源域模型**（本文的模型保存下来）。

方法：利用 **信息最大化** (Information Maximization)。固定住模型参数，只微调特征提取器，使得目标域数据在通过模型时，输出的熵 (Entropy) 最小（即分类尽可能确定）。这不需要源域数据也能实现适配。